

Projekt z przedmiotu: "Wielowymiarowa analiza danych" | **Grupa:** IZlwE2 2.1 IP

Temat: Analiza plam słonecznych | **Autor:** Kondraciuk Jakub, 98038 | **Data wykonania:** 13.01.2026r.

1. Import bibliotek

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import warnings
from scipy import stats
from scipy.fft import fft, fftfreq

warnings.filterwarnings('ignore')
sns.set_style("whitegrid")
plt.rcParams['figure.figsize'] = (14,6)
plt.rcParams['font.size'] = 12
```

Komentarz:

1. Import bibliotek:

- pandas - obsługa danych w formie DataFrame
- numpy - operacje numeryczne
- matplotlib.pyplot - wykresy statyczne
- seaborn - zaawansowane wykresy statyczne
- warnings - kontrola wyświetlania ostrzeżeń
- scipy.stats - funkcje statystyczne
- scipy.fft - szybka transformata Fouriera

2. Początkowe ustawienia:

- wyłączenie wszystkich ostrzeżeń
- ustawienie stylu wykresów Seaborn

2. Wczytanie danych

```
from google.colab import drive

drive.mount('/content/drive')
file_path = '/content/drive/MyDrive/Colab Notebooks/SN_d_tot_V2.0.txt'

df = pd.read_csv(file_path, delim_whitespace=True, header=None,
                  names=['Year', 'Month', 'Day', 'DecYear', 'Sunspots', 'Errc
```

```
on_bad_lines='skip')

print(f"Wczytano {len(df)} wierszy")

print(df.head())
```

Drive already mounted at /content/drive; to attempt to forcibly remount, call `drive.mount('/content/drive')`

Wczytano 75787 wierszy

	Year	Month	Day	DecYear	Sunspots	Error	Observations
0	1818	1	1	1818.001	-1	-1.0	0
1	1818	1	2	1818.004	-1	-1.0	0
2	1818	1	3	1818.007	-1	-1.0	0
3	1818	1	4	1818.010	-1	-1.0	0
4	1818	1	5	1818.012	-1	-1.0	0

Komentarz:

1. Import biblioteki google.colab
2. Połączenie z Google Drive
3. Liczba wczytanych wierszy = 75787
4. Pierwsze 5 wierszy to pierwsze 5 dni stycznia 1818 roku

3. Preprocessing danych

```
missing_count = (df['Sunspots'] == -1).sum()
print(f"Brakujące dane: {missing_count} wierszy")
```

Brakujące dane: 3247 wierszy

Komentarz:

1. Zbiór zawiera brakujące dane w kolumnie "Sunspots", więc musimy to odpowiednio obsłużyć
2. Liczba brakujących wierszy = 3247

```
df['Sunspots_orig'] = df['Sunspots'].copy()
df['Sunspots'] = df['Sunspots'].replace(-1, np.nan)
df['Sunspots_interp'] = df['Sunspots'].interpolate(method='linear')
```

Komentarz:

1. Zamieniamy brakujące wartości na NaN i uzupełnienie ich poprzez interpolację liniową między dostępnymi punktami

```
df['Date'] = pd.to_datetime(df[['Year', 'Month', 'Day']], errors='coerce')
```

Komentarz:

1. Tworzenie nowej kolumny z pełną datą

```
df.sort_values('Date', inplace=True)
df.reset_index(drop=True, inplace=True)
```

Komentarz:

1. Sortowanie wierszy według kolumny Date od najwcześniejszej do najpóźniejszej daty

```
print(f"Brakujące wartości po zamianie i interpolacji: {df['Sunspots_interp'].isna().sum()}")
print(f"Zakres dat: {df['Date'].min()} do {df['Date'].max()}")
```


Brakujące wartości po zamianie i interpolacji: 7
Zakres dat: 1818-01-01 00:00:00 do 2025-06-30 00:00:00

Komentarz:

1. Wyświetlenie podstawowych informacji po obróbce danych:
 - Brakujące wartości = 7
 - Zakres dat = 1818-01-01 00:00:00 - 2025-06-30 00:00:00

4. Wizualizacja szeregów czasowych

```
plt.figure(figsize=(16,6))
plt.plot(df['Date'], df['Sunspots_interp'], color='darkgreen', alpha=0.6, lw=2)
plt.fill_between(df['Date'], 0, df['Sunspots_interp'], color='green', alpha=0.3)
plt.title("Dzienne liczby plam słonecznych 1818-2025")
plt.xlabel("Rok")
plt.ylabel("Liczba plam słonecznych")
plt.show()
```



Komentarz:

1. Narysowanie wykresu szeregów czasowych dziennych liczb plam słonecznych
2. Wykres:
 - Wykres ilustruje zmienność aktywności słońca mierzoną poprzez liczbę plam słonecznych obserwowanych każdego dnia w okresie 1818–2025
 - Oś X - przedział czasowy od 1818 do 2025 roku
 - Oś Y - pokazuje dzienną liczbę plam słonecznych

5. Statystyki opisowe

```
sunspots_clean = df['Sunspots_interp'].dropna()


stats_summary = {
    'Średnia': sunspots_clean.mean(),
    'Mediana': sunspots_clean.median(),
    'Odchylenie std': sunspots_clean.std(),
    'Wariancja': sunspots_clean.var(),
    'Skośność': stats.skew(sunspots_clean),
    'Kurtoza': stats.kurtosis(sunspots_clean),
```

```
'Minimum': sunspots_clean.min(),
'Maksimum': sunspots_clean.max()
}

for k,v in stats_summary.items():
    print(f"{k:20}: {v:.2f}")

plt.figure(figsize=(14,5))
sns.histplot(sunspots_clean, bins=100, kde=True, color='orange')
plt.title("Rozkład dziennej liczby plam słonecznych")
plt.show()
```

Średnia	: 83.71
Mediana	: 64.00
Odchylenie std	: 77.37
Wariancja	: 5985.62
Skośność	: 1.09
Kurtoza	: 0.95
Minimum	: 0.00
Maksimum	: 528.00



Komentarz:

1. Obliczamy podstawowe statystyki opisowe dziennych liczb plam słonecznych:

- Średnia : 83.71
- Mediana : 64.00
- Odchylenie std : 77.37
- Wariancja : 5985.62

- Skośność : 1.09
- Kurtoza : 0.95
- Minimum : 0.00
- Maksimum : 528.00

2. Wykres:

- Przedstawia rozkład dziennej liczby plam słonecznych na podstawie wartości interpolowanych
- Oś X - liczba plam słonecznych
- Oś Y - liczba dni, w których zaobserwowano dana liczbę plam

6. Analiza wrażliwości na skalę czasową

```
monthly = df.resample('M', on='Date')['Sunspots_interp'].mean()
yearly = df.resample('Y', on='Date')['Sunspots_interp'].mean()

def calc_stats(series):
    return {
        'Średnia': series.mean(),
        'Wariancja': series.var(),
        'Skośność': stats.skew(series),
        'Kurtoza': stats.kurtosis(series)
    }

time_scales = {
    'Dzienne': calc_stats(sunspots_clean),
    'Miesięczne': calc_stats(monthly.dropna()),
    'Roczne': calc_stats(yearly.dropna())
}

pd.DataFrame(time_scales).T
```

	Średnia	Wariancja	Skośność	Kurtoza	
Dzienne	83.710273	5985.617816	1.092206	0.945219	
Miesięczne	83.700860	4658.614887	0.852581	0.133306	
Roczne	83.808399	4067.295787	0.689858	-0.380097	

Komentarz:

1. Analizujemy wpływ agregacji czasowej na statystyki danych:

- Dzienne:
 - Średnia = 83.71
 - Wariancja = 5985.62
 - Skośność = 1.09
 - Kurtoza = 0.95

- Miesięczne:

- Średnia = *83.70*
- Wariancja = *4658.61*
- Skośność = *0.85*
- Kurtoza = *0.13*

- Roczne:

- Średnia = *83.81*
- Wariancja = *4067.30*
- Skośność = *0.69*
- Kurtoza = *-0.38*


2. Średnia: pozostaje prawie taka sama przy wszystkich skalach, co pokazuje stabilny poziom aktywności słonecznej
3. Wariancja: maleje wraz z uśrednianiem, co oznacza zmniejszenie krótkoterminowych wahań
4. Skośność: spada przy agregacji, wskazując, że rozkład staje się bardziej symetryczny
5. Kurtoza: zmniejsza się przy większych skalach, co oznacza redukcję wartości ekstremalnych i wygładzenie rozkładu

7. Analiza autokorelacji

```
def autocorr(x, max_lag=5000):
    n = len(x)
    x_centered = x - np.mean(x)
    corr = np.correlate(x_centered, x_centered, mode='full')[n-1:] / (np.var
    return corr[:max_lag]

acf_values = autocorr(sunspots_clean.values)
lags_years = np.arange(len(acf_values)) / 365.25 # zamiana na lata

plt.figure(figsize=(12,5))
plt.plot(lags_years, acf_values, color='purple')
plt.axvline(11, color='red', linestyle='--', label='~11 lat')
plt.title("Autokorelacja dziennej liczby plam słonecznych")
plt.xlabel("Lag [lata]")
plt.ylabel("Autokorelacja")
plt.legend()
plt.show()
```



Komentarz:

1. Obliczanie i wizualizacja funkcji autokorelacji (ACF) dziennej liczby plam słonecznych
2. Wykres:
 - Wyraźnie widoczne regularne oscylacje autokorelacji
 - Okres = 11 lat, co zostało zaznaczone na wykresie
 - Ujemne minima przy połowie okresu
 - Brak trendu w autokorelacji

8. Analiza widmowa

```


N = len(sunspots_clean)
T = 1/365.25
yf = fft(sunspots_clean.values - sunspots_clean.mean())
xf = fftfreq(N,T)[:N//2]
amplitude = 2.0/N * np.abs(yf[:N//2])

plt.figure(figsize=(12,5))
plt.plot(xf, amplitude)
plt.axvline(1/11, color='red', linestyle='--', label='~11 lat')
plt.axvline(1/22, color='orange', linestyle='--', label='~22 lata')
plt.title("Widmo FFT dziennej liczby plam słonecznych")

```



```
plt.xlabel("Częstotliwość [1/rok]")  
plt.ylabel("Amplituda")  
plt.xlim([0,1])  
plt.legend()  
plt.show()
```



Komentarz:

1. Przeprowadzenie analizy widmowej sygnału za pomocą FFT (Fast Fourier Transform)
2. Wykres:
 - Zakres częstotliwości: od 0.00 do 1.00 1/rok
 - Najsilniejsze składowe (największe amplitudy):
 - 0.08 1/rok: amplituda 15.0 (okres 12.5 lat) – dominująca
 - 0.16 1/rok: amplituda 12.0 (okres 6.25 lat)
 - 0.04 1/rok: amplituda 12.0 (okres 25 lat)
 - Składowa stała (częstotliwość 0.00) – amplituda 6.0 (wartość średnia sygnału)
 - Wyższe częstotliwości (>0.4 1/rok) mają małe amplitudy (2.5–4.0), co może odpowiadać szumowi


9. Analiza czasowo-częstotliwościowa

```
import pywt

# Uśrednienie miesięczne w celu przyspieszenia obliczeń
monthly_signal = monthly.dropna().values - np.mean(monthly.dropna().values)
time_months = monthly.dropna().index.year + (monthly.dropna().index.month-1)

scales = np.arange(1,256)
coef, freqs = pywt.cwt(monthly_signal, scales, 'cmor1.5-1.0', 1/12)
power = np.abs(coef)**2
periods = 1 / freqs

plt.figure(figsize=(15,8))
plt.pcolormesh(time_months, periods, power, shading='auto', cmap='inferno')
plt.yscale('log')
plt.ylim([2,40])
plt.axhline(11, color='cyan', linestyle='--', label='Cykl Schwabe (~11 lat)')
plt.axhline(22, color='lime', linestyle='--', label='Cykl Hale (~22 lata)')
plt.colorbar(label='Moc')
plt.title("Skalogram falkowy (CWT) dzienne liczby plam słonecznych")
plt.xlabel("Rok")
plt.ylabel("Okres [lata]")
plt.legend()
plt.show()
```



Komentarz:

1. Przeprowadzenie analizy czasowo-częstotliwościowej za pomocą ciągłej transformaty falkowej (CWT)
2. Wykres:
 - Cykl Schwabe (~11 lat) – widoczne jako powtarzające się pasma wysokiej mocy w skali czasowej około 11 lat, co odpowiada podstawowemu cyklowi aktywności słonecznej
 - Cykl Hale (~22 lata) – dłuższy cykl widoczny jako zmiany w charakterystyce falowej na przestrzeni około 22 lat, związany z odwróceniem pola magnetycznego Słońca

10. Podsumowanie

- Dane obejmują dzienne obserwacje plam słonecznych w latach 1818–2025
- Liczba wierszy: 75 787; brakujące dane (-1) zastąpiono NaN i uzupełniono interpolacją
- Po interpolacji pozostało tylko 7 brakujących wartości
- Stworzono kolumnę z pełną datą i uporządkowano dane chronologicznie
- Średnia dzienna liczba plam: 83.71
- Mediana: 64, odchylenie standardowe: 77.37, wariancja: 5985.62
- Rozkład dziennych plam jest prawoskośny (skośność 1.09) i lekko spiczasty (kurtoza 0.95)
- Zakres dziennych wartości: 0–528 plam
- Histogram dziennych danych pokazuje liczne wartości ekstremalne i wysoką zmienność krótkoterminową
- Agregacja miesięczna i roczna zmniejsza wariancję, skośność i kurtozę – rozkład staje się bardziej symetryczny i łagodny
- Średnia liczba plam pozostaje stabilna niezależnie od skali czasowej (~83–84)
- Analiza autokorelacji pokazuje regularne oscylacje z dominującym cyklem ~11 lat (cykl Schwabe)
- Ujemne minima autokorelacji występują przy połowie cyklu (~5.5 lat)
- Analiza FFT potwierdza wyraźne składowe o okresach: ~12.5 lat, ~6.25 lat i ~25 lat
- Wyższe częstotliwości mają niskie amplitudy – odpowiadają szumowi krótkoterminowemu
- Analiza CWT pokazuje wyraźny cykl Schwabe (~11 lat) i cykl Hale (~22 lata) w skali czasowej
- Skalogram falkowy ujawnia lokalną zmienność częstotliwościową w czasie
- Krótkoterminowe wahania dzienne są znaczne, ale średnia aktywność jest stabilna w długim okresie
- Dane wykazują charakter cykliczny i powtarzalny, zgodny z oczekiwaniami fizycznymi dotyczącymi Słońca
- Agregacja danych do skali miesięcznej lub rocznej pozwala wyraźnie zobaczyć główne cykle i wygładzić szum